

基于惯性/磁传感器的人体活动模式识别系统设计实现

课程论文 | 福建理工大学 智能科学与技术 | 《模式识别与统计学习》专周实训

孔子瑜（算法与工程）、李宝平（数据采集与固件） | 导师：郑积仕

摘要

人体活动识别（HAR）是可穿戴计算与健康监护的核心技术。本文完成了一套从传感器标定到模式分类的全链路 HAR 系统设计与实现。基于 ESP32-S3 + MPU6050 + HMC5883L 硬件平台，以 50Hz 采样 9 通道惯性/磁力数据，采集 2 名被试的 7 类日常活动（静坐、站立、步行、跑步、上楼、下楼、跌倒），共计 566 个滑动窗口。经六位置加速度标定（RMSE 11.35→0.42 m/s²）、椭圆拟合磁力计标定（改善 76.1%）、0.3Hz 去重力与 20Hz 抗混叠滤波后，提取 294 维时频域特征。系统对比了 6 类特征选择方法与 13 种分类模型，采用留一被试（LOSO）交叉验证、McNemar 显著性检验和 Bootstrap 置信区间保证评估严谨性。最佳模型为 kNN（k=3, 距离加权），LOSO 准确率 56.4%，经滑窗多数表决时序平滑后提升至 59.5%。实验发现静坐与站立的跨被试特征分布偏移是核心瓶颈（sit recall=0%），1D-CNN 端到端模型在极少量数据下 sit recall 达 50%——验证了原始信号中存在手工特征遗漏的判别信息。本文坦诚分析了结果局限，提出了数据增强、特征优化与模型升级的改进路线。

关键词：人体活动识别；模式识别；MEMS 惯性传感器；特征工程；LOSO 交叉验证

1 引言

1.1 研究背景

随着 MEMS 惯性传感器在智能手机、智能手表等可穿戴设备中的普及，基于加速度计、陀螺仪和磁力计的人体活动识别（Human Activity Recognition, HAR）成为普适计算领域的研究热点。HAR 技术在健康监护（跌倒检测）、运动量化、智能家居和康复医疗等场景具有广泛应用价值。

传统 HAR 研究依赖公开数据集（如 UCI HAR、WISDM、PAMAP2），但数据采集条件与真实部署环境存在差异。本课题的独特价值在于完成从硬件设计、传感器标定、数据采集到算法开发的全链路工程闭环——每一步的工程决策都直接影响最终识别性能。

1.2 相关工作

HAR 的研究范式经历了从手工特征+传统分类器到深度学习端到端的演变。Bulling 等人（2014）系统综述了可穿戴 HAR 的信号处理与模式识别方法。Anguita 等人（2013）公开的 UCI HAR 数据集采用 561 维特征+ SVM 的经典方案，在 30 名被试上达到 96% 准确率。Ordóñez 和 Roggen（2016）提出 DeepConvLSTM 架构，在 Opportunity 数据集上取得领先性能。

然而，大多数研究集中于算法层面，忽略了传感器标定这一基础环节。Raw 数据中的零偏、刻度误差和非正交性会系统性扭曲特征分布，降低分类器泛化能力。本项目从传感器物理模型出发，将标定嵌入预处理流水线，并通过标定增益分析量化其对识别精度的影响。

1.3 本文贡献

- 完成从 PCB 设计、传感器标定、固件开发到模式识别算法的全链路工程实践

- 2. 系统对比 6 种特征选择方法 (Filter/Wrapper/Embedded)、3 种降维技术 (PCA/LDA/t-SNE) 和 13 种分类模型 (线性/非线性/集成/深度学习)
- 3. 采用 LOSO 留一被试交叉验证、McNemar 显著性检验和 Bootstrap 置信区间等严谨评估手段, 给出可靠的实验结论
- 4. 通过 HMM 时序平滑、1D-CNN 和无监督聚类三个方向的进阶探索, 深入分析了模型的改进空间与数据的内在结构

2 系统硬件与数据采集

2.1 采集协议与被试设计

参数	设定值
传感器	MPU6050 (加速度+陀螺仪) + HMC5883L (磁力计)
采样率	50 Hz
佩戴位置	腰部 (Y 轴指向前进方向)
被试	2 人 (S01, S02)
活动类别	静坐(0), 站立(1), 步行(2), 跑步(3), 上楼(4), 下楼(5), 跌倒(6)
每类每次时长	前 6 类 65s, 跌倒 15s
每类次数	1 次 (受限于采集条件)
过渡处理	每 trial 首尾各裁 2s

采集序列固定为：静坐→站立→步行→跑步→上楼→下楼→跌倒，ESP32-S3 离线固件通过 NeoPixel RGB LED 指示当前状态（白=编号, 橙=倒计时, 绿=采集中, 蓝=OK, 红=出错）。

2.2 传感器标定

加速度计六位置标定

采用 12 参数误差模型： $\mathbf{a_calibrated} = \mathbf{M} \times (\mathbf{a_raw} - \mathbf{b})$ ，其中 M 为 3×3 刻度+非正交矩阵，b 为 3×1 零偏向量。将传感器静止摆放于 ±X、±Y、±Z 六位置，每位置采集 5-10s 取均值，以静止时合加速度模长 = 1g (9.81 m/s²) 为约束，最小二乘求解 12 参数。

标定结果：RMSE 从 11.35 m/s² 降至 0.42 m/s² (改善 96.3%)。

磁力计椭球拟合

手持传感器在空中画 8 字+多轴旋转 (3000 样本)，一般二次曲面直接最小二乘 (DLS) 拟合椭球方程，SVD 分解求解硬铁偏置 (椭球中心) 与软铁形变矩阵 (椭球轴长与旋转)。

标定结果：norm_std 从 7.44 uT 降至 1.22 uT (改善 76.1%)。重标定前为 4.78 uT (35.8%)，重标定使覆盖度大幅提升。

陀螺仪零偏与 Allan 方差

静态零偏 (取 30s 静止段均值)：[-4.29, -1.21, 0.67] °/s。Allan 方差分析通过长时间静置 (≥30 min) log-log 曲线读取出角随机游走 (ARW) 和零偏不稳定性 (BI)。

2.3 PCB 扩展板设计

ESP32-S3 Shield PCB 基于 KiCad 手动绘制原理图，导出 Gerber 后嘉立创打样。关键设计约束：

- 磁力计距 ESP32 天线 $\geq 15\text{mm}$ (防电磁干扰)
- I²C 上拉电阻 $4.7\text{k}\Omega \times 2$ 、去耦电容 $100\text{nF} \times 2$ 靠近芯片
- 2 层板, $\leq 60 \times 30\text{mm}$, 模块可插拔 (J1-J4 排母降焊接风险)

手工焊接完成后 I²C 扫描验证：0x68 (MPU6050) + 0x1E (HMC5883L) 均正常通信。初始 SDA/SCL 焊锡桥接短路已修复。

2.4 数据质量与划分策略

划分策略：严格采用 LOSO (Leave-One-Subject-Out)，按 subject_id 划分训练/测试集。每折训练集含 1 名被试全部窗口 (283 窗口)，测试集含另 1 名被试全部窗口 (283 窗口)，共 2 folds。

为什么不使用随机 k-fold：同一被试的相邻窗口 (50% 重叠, 间隔仅 1.28s) 高度相关。若随机分配窗口，模型可以“见过”测试被试的几乎相同数据，泛化能力被严重高估。这是任务书明确指出的企业级红线——按窗口随机划分直接不合格。

数据集统计：

指标	值
被试数	2
总窗口数	566 (S01=283, S02=283)
窗口形状	(566, 128, 9)
类分布	前 6 类各 92 窗口，跌倒 14 窗口

3 信号预处理与窗口化

3.1 预处理流水线

raw CSV → 校准(calib_params.json) → 裁剪首尾各 2s
→ 去重力(HP 0.3Hz, 4阶 Butterworth) → 低通滤波(LP 20Hz, 4阶)
→ 滑动窗口(2.56s, 128点, 50%重叠) → 窗口标签(多数表决)

去重力：加速度计输出 = 运动加速度 + 重力加速度的叠加。重力集中在 0 Hz 附近，用 0.3 Hz 高通 Butterworth 滤波器分离，保留 >0.5 Hz 的步态频段。**低通滤波：**人体运动能量集中在 0.5-15 Hz，20 Hz 截止频率在抗混叠的同时保留全部有效信号。

3.2 滑动窗口参数

参数	设定值	理由
窗口长	2.56s (128 点 @50Hz)	包含 1-2 个完整步态周期 (~2 Hz)；128 为 2^7 , FFT 友好
重叠率	50%	HAR 文献标准，平衡样本量与时间分辨率
标签策略	多数表决 (mode)	窗口内取众数，异常值鲁棒

3.3 数据集统计

预处理后输出 `windowed_dataset.npz`：形状 (566, 128, 9)，9 通道包含 `ax/ay/az/gx/gy/gz/mx/my/mz`。每被试 283 窗口，按活动类型分组：前 6 类各 46 窗口（S01/S02 各 46），跌倒各 7 窗口。

4 特征工程

4.1 时域特征（14 维/轴）

特征	物理含义
mean	信号直流分量
std, var, rms	运动强度（核心区分准静态与动态活动）
peak_to_peak, max, min	极端变化幅度
median, iqr	鲁棒中心与离散度
skew	分布不对称性（上楼正偏 vs 下楼负偏）
kurtosis	分布尾重（冲击性活动 vs 周期性活动）
sma	信号幅值面积
zero_cross_rate	振荡频繁度
autocorr_lag1	一阶自相关（周期性判别）

4.2 频域特征（10 维/轴）

特征	物理含义
dominant_freq	主频/步频（步行 ~2 Hz, 跑步 ~3 Hz）
spectral_centroid	频谱能量重心
spectral_entropy	频谱有序度（周期性 vs 随机性）
energy_low/mid/high	三频带能量比（0-3/3-8/8-20 Hz）
bandwidth	有效带宽
flatness	频谱平坦度（白噪声=1, 纯音=0）
rolloff	频谱滚降点（85% 能量所在频率）
peak_count	显著谱峰数量

4.3 复合/跨轴特征

除单轴特征外，额外提取合加速度模长、合角速度模长、合磁场模长各 24 维（14 时域+10 频域），以及轴间相关系数（3）、加加速度统计（3）、垂直/水平能量比、磁航向标准差等 12 维复合特征。

特征矩阵: (566, 292), 其中 2/294 特征因方差为零 (磁力计频域平坦度/滚降点, 物理合理) 被自动过滤。

4.4 特征选择与降维

Filter 方法

- **ANOVA F:** 单变量 F 检验, Top-30 特征 CV accuracy 88.5%
- **互信息 (MI) :** 非线性依赖度量, Top-30 特征 CV accuracy 89.2%

Wrapper 与 Embedded 方法

方法	最佳维度	CV Accuracy	特点
SFS (前向搜索)	30	90.8%	ANOVA Top-100 预筛加速
RFE (RF 递归消除)	30	91.7%	综合最优
RF MDI (重要性排序)	Top-30	90.1%	可解释性强
L1 (LR 正则化)	稀疏选择	82.3%	高维多重共线性影响

PCA 与 LDA

- **PCA:** 前 25 维保留 95% 方差, 前 50 维保留 99% 方差。用于聚类预处理效果显著 (ARI 0.17→0.36)
- **LDA:** 最多 6 维 (7 类-1)。高维小样本 (292 特征 vs 566 样本) 下类内协方差矩阵接近奇异, SVD 求解失效 (acc=23.3%)

t-SNE 可视化

2D 嵌入图显示 walk/run/upstairs 形成清晰簇边界, sit 和 stand 样本空间高度重叠, 预示两类难以通过静态特征区分。见 `d5_tsne.png`。

5 模式识别建模

5.1 贝叶斯决策与线性分类器

6 基线模型 LOSO 评估结果:

模型	Accuracy	Macro F1	特点
kNN (k=5)	0.555	0.493	简单有效
LogisticRegression	0.525	0.490	线性基线
LinearSVM	0.467	0.426	线性不可分
GaussianNB	0.488	0.442	强特征独立假设
DecisionTree	0.376	0.329	严重过拟合
LDA	0.233	0.192	高维失效

最小风险贝叶斯：按任务书 §3.6 设计代价矩阵——跌倒漏检（真跌倒判为非跌倒）代价 ×10，其余误分类代价 = 1。跌倒召回率从 42.9% 提升至 57.1% (+14.2pp)，以整体 accuracy 微降 0.9pp 为代价。

5.2 非线性分类器与集成学习

7 高级模型 + GridSearchCV 内嵌 LOSO（每 fold 内 3-fold CV 调参）：

模型	最佳参数	Accuracy	Macro F1
kNN	k=3, weight=distance	0.564	0.527
MLP	hidden=(128,64), alpha=0.0001	0.507	0.472
RBF_SVM	C=1, gamma=scale	0.472	0.430
RandomForest	n=200, max_depth=None	0.424	0.386
AdaBoost	n=200, lr=0.1	0.389	0.343
GBDT	n=100, lr=0.01, depth=3	0.281	0.227
DecisionTree	max_depth=10	0.376	0.329

kNN 胜出分析：小样本（每 fold 仅 283 训练窗口）场景下，基于实例的非参数方法优于需要大量数据估计参数的模型。RF/GBDT 等集成方法因样本不足导致树深度受限、方差大。MLP 表现中等但不及 kNN。

5.3 超参数调优

GridSearchCV 搜索空间（以 kNN 为例）：

- `n_neighbors` ∈ {3, 5, 7, 9}
- `weights` ∈ {uniform, distance}

每 fold 最优参数：Fold 1 (训 S02→测 S01): k=3, distance；Fold 2 (训 S01→测 S02): k=3, distance。两 fold 一致，说明 k=3+distance 组合稳定。

6 实验结果与分析

6.1 多模型性能对比

见表 1（§5.1-5.2 两表合并），完整模型排名与 per-class recall 见附录。最优模型 kNN (k=3, distance)：

类别	Precision	Recall	F1	Support
sit	0.00	0.00	0.00	92
stand	0.37	0.65	0.47	92
walk	0.63	0.93	0.75	92
run	0.56	0.55	0.56	92
upstairs	0.67	0.84	0.74	92
downstairs	0.68	0.42	0.52	92
fall	0.86	0.43	0.57	14

图 1：混淆矩阵

见 `d8_confusion_matrix.png`。sit 的 92 个样本全部被误分类——Fold 1 中主要被判为 run/downstairs，Fold 2 中 46/46 被判为 stand。这反映了跨被试场景下传感器佩戴角度差异导致的 sit 特征分布严重偏移。

图 2：ROC 曲线 (OvR)

见 `d8_roc_curves.png`。各类 AUC 反映了一对多可分性：walk AUC 最高（与其他类显著不同），sit AUC 接近 0.5（几乎随机）。

6.2 标定增益

标定参数文件 `calib/calib_params.json` 已就绪（加速计 RMSE 改善 96.3%、磁力计改善 76.1%）。由于采集条件限制（真实数据直接使用标定后数据），标定 vs 未标定的精度对比以标定报告中的原始信号改善为代理指标。完整标定增益量化需保留未标定采集作为对照。

6.3 易混类分析

排名	混淆对	次数	物理原因
1	sit → stand	46	准静态活动，加速度均≈1g，角速度≈0
2	sit → run/downstairs	46	跨被试特征分布偏移，Fold 1 中 sit 被判为动态活动
3	upstairs ↔ downstairs	~26	步态周期性相近，仅垂直加速度方向相反
4	walk ↔ upstairs	~10	步频重叠（1.5-2 Hz），上楼加速度幅值略大
5	fall → run	~4	跌倒冲击脉冲与跑步落地峰值时域幅值接近

6.4 显著性检验

对比	n_ab	n_ba	χ^2	p	显著?
kNN vs RBF_SVM	—	—	—	<0.0001	是

McNemar 检验拒绝两模型错误率相同的零假设，确认 kNN 优于 RBF_SVM 非随机波动。Bootstrap 1000 次重采样得 kNN accuracy 95% CI: [0.512, 0.594]。

7 进阶探索

D9 阶段针对 D8 暴露的两个核心问题（sit recall=0%，整体 accuracy 偏低）从三个方向开展进阶探索。

7.1 时序平滑

方法：

- **滑窗多数表决**：在 kNN 预测序列上滑动 L 窗口（L=3,5,7），窗口内多数投票决定中心点标签
- **HMM Viterbi 解码**：从训练标签估计 7×7 状态转移矩阵，以 kNN 预测概率为发射概率，Viterbi 算法求最优状态序列
- 平滑在每 trial 段内独立进行（按标签断点分割），避免跨活动平滑

结果：

方法	Accuracy	Macro F1	walk	upstairs	fall	sit
kNN (raw)	0.564	0.527	0.935	0.837	0.429	0.000
MV L=5	0.583	0.560	0.989	0.891	0.500	0.000
MV L=7	0.595	0.569	1.000	0.935	0.500	0.000
HMM	0.583	0.550	0.978	0.891	0.429	0.000

分析：时序平滑有效消除了 walk/upstairs/fall 的偶发抖动误差（acc +3.1pp），但 sit recall 恒为 0%。深入分析发现 kNN 对 sit 的平均 $P(\text{sit}) < 0.01$ 、 $P(\text{stand}) > 0.92$ （Fold 2），平滑在“全判为 stand”的序列上投票只会固化错误。**时序平滑能修正偶发错误，无法修复特征级系统性混淆。**

7.2 1D-CNN 端到端

架构：3 层卷积（64/128/256 通道，kernel=5/5/3）+ BatchNorm + MaxPool + GlobalAvgPool + Dense(64) + Dropout(0.3)，~200K 参数，16 batch，早停 patience=15。

结果：Accuracy 仅 25.1%，远低于手工特征+kNN。566 窗口对深度学习严重不足，每折仅 283 训练样本。**但 sit recall = 50%——这是所有模型中唯一检测到 sit 的。**CNN 完全丢失了 stand/walk 的判别能力（recall=0%），与 kNN 形成鲜明互补：kNN 找不到 sit 但动态活动分类尚可，CNN 能找到 sit 但其他类几乎随机。

启示：原始时序信号中确实存在 sit/stand 的可分辨信息（可能与姿态角导致的直流偏置模式有关），但 294 维手工特征未能有效捕获。深度特征与手工特征的融合是值得探索的方向。

7.3 无监督聚类

方法：K-means 和 GMM（全协方差）在原始 292 维和 PCA-30 维空间分别聚类，ARI/NMI/AMI 评估。

结果：

方法	ARI	NMI	AMI
KMeans (292D)	0.173	0.268	0.253
GMM (292D)	0.158	0.269	0.254
KMeans+PCA	0.364	0.516	0.507
GMM+PCA	0.353	0.516	0.506

分析：PCA 降维使聚类质量翻倍（ARI 0.17→0.36），验证了 292 维特征中存在大量冗余/噪声。ARI=0.364 远超随机基线（0），说明数据存在显著类别结构，但与理想聚类（ARI=1）的差距反映了 sit/stand/downstairs 等类在静态特征空间中的内在重叠。t-SNE 可视化（见 d9_clustering_tsne.png）直观展示了这一结构。

8 总结与展望

8.1 工作总结

本文完成了基于惯性/磁传感器的 HAR 系统全链路设计与实现：

- 1. **硬件层：**ESP32-S3 Shield PCB 设计→打样→焊接→I²C 验证→固件开发→真实数据采集（2 被试，566 窗口）
- 2. **信号层：**三传感器标定（加速度计 RMSE 改善 96.3%，磁力计改善 76.1%）→预处理流水线（去重力/滤波/窗口化）
- 3. **特征层：**294 维时频域+复合特征提取→6 种特征选择方法系统对比→RFE 30 维最优（CV 91.7%）→PCA 降维
- 4. **分类层：**13 种模型（线性/非线性/集成/深度学习）LOSO 评估→kNN(k=3,distance) 最优（56.4%）
- 5. **评估层：**混淆矩阵+易混类物理分析+McNemar 显著性检验（p<0.0001）+Bootstrap 95% CI [51.2%, 59.4%]
- 6. **探索层：**时序平滑（acc ↑3.1pp）+1D-CNN（sit recall 50%）+无监督聚类（ARI=0.364）

8.2 不足与改进

- 1. **被试数量有限**（2 人）：LOSO 仅 2 folds，统计意义受限。补充 5+ 被试是提升泛化性的首要任务
- 2. **静坐完全不可分**：跨被试传感器姿态差异导致 sit 特征分布严重偏移，需加入姿态角特征或域自适应方法
- 3. **跌倒样本极少**（14 窗口）：不平衡比 6.6:1，建议增加采集时长或使用 SMOTE 等过采样
- 4. **CNN 严重欠拟合**：566 窗口对深度学习不足。迁移学习（预训练 HAR 模型微调）可能突破数据瓶颈
- 5. **特征冗余度高**：PCA 降维使聚类 ARI 翻倍，说明 292 维中约 90% 为冗余，可进一步精简到 30-50 维

8.3 个人收获

孔子瑜（算法与工程）：

通过本课题完成了从“会掉包”到“真懂算法”的转变。理解了特征工程的物理直觉（为什么上楼偏度为正、下楼为负）、评估方法的严谨性要求（LOSO 不是可选项而是必须）、传感器标定对识别精度天花板的量化影响。最有价值的收获是坦诚面对“失败”——sit recall=0% 比 walk=100% 教给我的更多。

李宝平 (数据采集与固件) :
掌握了 I²C 总线调试、传感器标定的物理操作、ESP32 MicroPython 固件开发全流程。PCB 焊接中 SDA/SCL 短路问题的排查让我深刻理解了硬件调试的系统性思维。HMC5883L 寄存器顺序 (X,Z,Y 非标准) 的发现过程是工程实践中"手册优先"原则的最好例证。

致谢

感谢郑积仕老师在项目全过程中的悉心指导，特别感谢老师在传感器标定方法论、LOSO 评估必要性和代价敏感决策方面的关键建议。感谢福建理工大学智能科学与技术专业提供的实验条件与课程平台。

参考文献

- 张学工.《模式识别》(第四版). 清华大学出版社, 2021.
- 李航.《统计学习方法》(第二版). 清华大学出版社, 2019.
- Bulling, A., Blanke, U., Schiele, B. "A Tutorial on Human Activity Recognition Using Body-worn Inertial Sensors." *ACM Computing Surveys*, 46(3): 1-33, 2014.
- Anguita, D., Ghio, A., Oneto, L., Parra, X., Reyes-Ortiz, J.L. "A Public Domain Dataset for Human Activity Recognition Using Smartphones." *ESANN*, 2013.
- Bao, L., Intille, S.S. "Activity Recognition from User-Annotated Acceleration Data." *Pervasive Computing*, pp. 1-17, 2004.
- Fitzgibbon, A., Pilu, M., Fisher, R.B. "Direct Least Square Fitting of Ellipses." *IEEE TPAMI*, 21(5): 476-480, 1999.
- Pedregosa, F., et al. "Scikit-learn: Machine Learning in Python." *JMLR*, 12: 2825-2830, 2011.
- Ordóñez, F.J., Roggen, D. "Deep Convolutional and LSTM Recurrent Neural Networks for Multimodal Wearable Activity Recognition." *Sensors*, 16(1): 115, 2016.

附录

A. 特征清单

见 docs/特征字典.md (294 特征 × 类型/公式/物理含义)。

B. 核心代码清单

文件	行数	职责
src/preprocess.py	503	信号预处理
src/features.py	448	特征提取
src/feature_selection.py	619	特征选择与降维
src/classifiers_baseline.py	403	基线分类器
src/models_advanced.py	347	高级模型与调参
src/evaluation.py	509	模型评估
src/d9_advanced_exploration.py	814	进阶探索

C. 采集协议

见 docs/数据采集协议.md。

D. 图表索引

图表	文件
混淆矩阵	d8_confusion_matrix.png
ROC 曲线	d8_roc_curves.png
模型排名	d8_model_ranking.png
特征选择对比	d5_method_comparison.png
PCA 累计方差	d5_pca_cumvar.png
t-SNE 可视化	d5_tsne.png
学习曲线	d7_learning_curves.png
时序平滑对比	d9_temporal_smoothing_recall.png
HMM 转移矩阵	d9_hmm_transition_matrix.png
CNN 对比	d9_cnn_comparison.png
聚类 t-SNE	d9_clustering_tsne.png
聚类指标	d9_clustering_metrics.png

E. AI 使用记录

见 AI_USAGE.md。核心算法原理、实验设计、结论均经人工审核，答辩随机抽问可讲清。